

這份教材補的是什麼

補充教材第 30 至 39 頁講梯度下降，十頁裡有更新式、有等高線圖、有損失地形，最後一頁寫「This is the “learning” of machines in deep learning」。

但是整段看完，沒有一個數字是算得出來的，也沒有一行程式可以跑。

這份補的就是那一段：**同一個例子，從手算走到手寫程式，再走到 TensorFlow 2 框架版，三邊的數字必須一樣。**

全份只用一個示範函數：

$$L(w) = (w - 3)^2 \quad \frac{dL}{dw} = 2(w - 3)$$

起點 $w^{(0)} = 0$ ，學習率 $\eta = 0.1$ 。最小值在 $w = 3$ ，一眼就看得出來——**示範題一定要選手算得出答案的，否則程式算錯你不會知道。**

怎麼用這份教材：先做第二節的手算練習，自己填完那張表；再把程式貼到 Colab 跑，確認跑出來的數字和你填的一樣；最後看第五節。全部做完大約 90 分鐘。

一、更新式

$$\theta^{(k+1)} = \theta^{(k)} - \eta \nabla L(\theta^{(k)})$$

符號	意思
θ	參數 parameters，就是模型要學的那些數字
L	損失函數 loss function，越小代表模型越準
η	學習率 learning rate，一步要走多遠
∇L	梯度， L 對各個參數的偏微分組成的向量


那個**減號**是重點。梯度指的是上坡方向，我們要往下坡走，所以減掉。

以起點 $w^{(0)} = 0$ 為例：

$$\left. \frac{dL}{dw} \right|_{w=0} = 2(0 - 3) = -6$$

梯度是負的，所以 w 往**正**的方向移動：

$$w^{(1)} = 0 - 0.1 \times (-6) = 0.6$$



損失曲線與前三步

二、手算練習

把下表填完。每一列都是同三個動作：算梯度、乘學習率、減掉。

k	$w^{(k)}$	$dL/dw = 2(w - 3)$	$\eta \times$ 梯度	$w^{(k+1)}$	$L(w^{(k)})$
0	0.000000	-6.000000	-0.600000	0.600000	9.000000
1	0.600000				
2					
3					
4					
5					
6		—	—	—	

填完之後對答案：

k	$w^{(k)}$	dL/dw	$L(w^{(k)})$
0	0.000000	-6.000000	9.000000
1	0.600000	-4.800000	5.760000
2	1.080000	-3.840000	3.686400
3	1.464000	-3.072000	2.359296
4	1.771200	-2.457600	1.509949
5	2.016960	-1.966080	0.966368
6	2.213568	-1.572864	0.618475

為什麼六步還沒走到 3

因為梯度下降是逐步逼近，不是一步到位。這個例子有閉式解可以反查：


$$w^{(k)} = 3 - 3(1 - 2\eta)^k$$

$\eta = 0.1$ 時 $(1 - 2\eta) = 0.80$ ，也就是每一步距離終點都只剩上一步的八成。損失從 9.000000 降到 0.618475，降幅越來越小——因為越靠近最小值，梯度越小，步伐自然就變短。

自己驗一次：把 $k = 3$ 代進閉式解， $3 - 3 \times 0.8^3 = 3 - 1.536 = 1.464$ ，和表上一樣。

三、學習率

補充教材第 37 頁說學習率會影響結果，但沒給數字。三種各跑五步：



三種學習率

k	$\eta = 0.01$	$\eta = 0.1$	$\eta = 1.05$
0	0.0000	0.0000	0.0000
1	0.0600	0.6000	6.3000
2	0.1188	1.0800	-0.6300
3	0.1764	1.4640	6.9930
4	0.2329	1.7712	-1.3923
5	0.2882	2.0170	7.8315

收斂係數是 $(1 - 2\eta)$ ：

η	$1 - 2\eta$	結果
0.01	0.98	每步只縮 2%，五步後還在 0.29，走不動
0.1	0.80	穩定收斂
1.05	-1.10	絕對值大於 1，每步放大並換邊，發散

判準很乾淨：

$$|1 - 2\eta| < 1 \iff 0 < \eta < 1$$


練習： $\eta = 0.5$ 時係數是多少？會發生什麼事？先算再跑。

四、兩個參數：等高線與鋸齒

補充教材第 31 頁寫「Gradient 是 Loss 等高線的法線方向」。用兩個參數的函數來看：

$$L(\theta_1, \theta_2) = \theta_1^2 + 10\theta_2^2 \quad \nabla L = (2\theta_1, 20\theta_2)$$

θ_2 的係數是 θ_1 的十倍，等高線被壓成狹長的橢圓。起點 $(3, 1)$ ， $\eta = 0.08$ 。



等高線與鋸齒路徑

k	θ_1	θ_2	$dL/d\theta_1$	$dL/d\theta_2$	L
0	3.0000	1.0000	6.0000	20.0000	19.0000
1	2.5200	-0.6000	5.0400	-12.0000	9.9504
2	2.1168	0.3600	4.2336	7.2000	5.7768
3	1.7781	-0.2160	3.5562	-4.3200	3.6282
4	1.4936	0.1296	2.9872	2.5920	2.3988
5	1.2546	-0.0778	2.5093	-1.5552	1.6346

鋸齒的來源在兩個方向的係數：

- θ_1 每步乘 $1 - 0.08 \times 2 = 0.84$ ，慢慢靠近
- θ_2 每步乘 $1 - 0.08 \times 20 = -0.60$ ，**係數是負的**，每一步都跨過去再跳回來

看 θ_2 那一欄的正負號：1.0 → -0.6 → 0.36 → -0.216，一直在換邊。

這就是小考 1 考過的那題：**各特徵尺度差距大時，梯度下降會在陡峭方向劇烈震盪、在平坦方向幾乎不動**。解法不是把學習率調小——調小之後平坦方向會更走不動。正確做法是先把特徵標準化，讓等高線變回接近圓形。

五、程式：手寫版與框架版

手寫版：自己算梯度

```
def loss(w):
    return (w - 3.0) ** 2

def grad(w):
    return 2.0 * (w - 3.0)    # 微分要自己推

w, eta = 0.0, 0.1
for k in range(7):
    g = grad(w)
    w = w - eta * g          # 更新式就是這一行
```

這十行就是補充教材那十頁的全部內容。印出來的 w 是 $0.000000 \rightarrow 0.600000 \rightarrow 1.080000 \rightarrow \dots$ ，與第二節手算的表完全一致。

框架版：讓 TensorFlow 算梯度

```
w = tf.Variable(0.0)
opt = tf.keras.optimizers.legacy.SGD(0.1)

for k in range(7):
    with tf.GradientTape() as tape:
        L = (w - 3.0) ** 2    # 只寫前向計算
    g = tape.gradient(L, w)    # 反向自動微分
    opt.apply_gradients([(g, w)])
```

和手寫版比，少寫的只有一行：微分。`GradientTape` 把前向計算錄下來，再自動反向算出梯度。一維的微分推得出來，層數一多就不可行了，這才是框架真正的價值。

兩版比對

k	手寫 NumPy 的 w	TensorFlow 2 的 w	差
0	0.000000	0.000000	0.0e+00
2	1.080000	1.080000	8.6e-08
4	1.771200	1.771200	1.2e-07
6	2.213568	2.213568	5.6e-08

最大差 1.91e-07，判定一致。這個差距來自單精度浮點數，不是演算法不同——TensorFlow 預設用 float32，NumPy 用 float64。

判準要先寫下來再跑：差小於 1e-5 才算通過。不先定判準，看到什麼數字都會覺得合理。

六、回到補充教材第 32 頁

那一頁給了三個參數和它們的梯度，但沒寫更新後是多少。補上：

	θ_1	θ_2	θ_3
投影片給的 θ	0.2	-0.1	0.3
投影片給的梯度	0.15	0.05	0.2
$\eta \times$ 梯度	0.015	0.005	0.02
更新後的 θ	0.185	-0.105	0.28

每一個參數都是「自己減掉學習率乘自己的偏微分」，彼此不互相影響。投影片 p32、p33 那一整排的 Compute，做的就是這件事。

差別只在參數從 3 個變成幾百萬個——**演算法一個字都沒變，變的是要算幾次**，這才是需要圖形處理器 Graphics Processing Unit (GPU) 的原因。

七、AI 時代，人在這裡做什麼

模型不收斂的時候，常見的有四種病因：

病因	症狀
① 學習率不對	損失上下跳或變成 NaN。看第三節那三張圖的右邊那張
② 特徵尺度不一致	損失降得很慢但沒發散。看第四節的鋸齒
③ 初始化不對	全零會讓同層神經元永遠同步更新，整層等於一個神經元
④ 梯度消失	輸出落在 sigmoid 飽和區，梯度趨近 0，深層幾乎不更新

這四種的症狀相似，處理方式完全不同，而程式一個錯誤訊息都不會給。

生成式 AI 可以把模型寫出來、也可以建議調參數，但「現在是哪一種病」要由人判斷。判斷的依據就是這份教材的內容：知道更新式長什麼樣、知道收斂係數怎麼算、知道鋸齒代表什麼。

框架版少寫的那一行微分，省下的是推導的力氣，不是理解的力氣。**框架算錯不會報錯**，它只會給你一個不收斂的模型；能用一個手算得出答案的小題目去驗證它，是這份教材真正要練的能力。

小考 1 的四道題考的正是這四件事。

八、練習

1. 把學習率改成 $\eta = 0.5$ 。先用收斂係數預測會發生什麼，**寫下你的預測**，再跑跑看。
2. 把二維的損失改成 $\theta_1^2 + \theta_2^2$ 。等高線會變成什麼形狀？鋸齒還在嗎？為什麼？
3. 框架版把 `SGD` 換成 `Adam`，數字還會和手寫版一樣嗎？為什麼？
4. 在第二節的表上，找出損失每一步的降幅： $9.000000 \rightarrow 5.760000 \rightarrow 3.686400 \rightarrow \dots$ 這些降幅之間有什麼規律？和收斂係數有關嗎？

前兩題用收斂係數就能先預測答案。**跑之前先寫下預測，再跑**——預測錯比預測對更有價值，那代表你對這個演算法的理解有一個洞。

程式取用

完整程式含三張圖的繪製，共 11 個可執行區塊：

- **直接在瀏覽器跑**：https://colab.research.google.com/github/pychang-ai/115-1-DLMA/blob/main/topics/gradient-descent/gradient_descent.ipynb 從課程 repo 的 README 進階主題那一列點「在 Colab 開啟」也是同一個連結。不必下載、不必安裝、不需要圖形處理器；要改內容請先在 Colab 選「複製到雲端硬碟」，否則改動不會留下來。
- 本機執行：`python code/gradient_descent.py`，需要 `numpy`、`matplotlib`、`tensorflow`

圖上的文字一律用英文。Colab 的預設環境沒有中文字型，用中文會變成方框。